

1. (10 puntos) Complete las demostraciones de las reglas de asignación de la presentación de la semana 7.

Regla de asignación

En el análisis discriminante se asigna $X = x$ a la clase con mayor $\delta_k(x)$ donde:

$$\delta_k(x) = x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

Teorema de Bayes: $P(B_i|A) = \frac{P(B_i \cap A)}{\sum_{k=1}^K P(B_i \cap A)} = \frac{P(B_i)P(A|B_i)}{\sum_{k=1}^K P(B_i)P(A|B_i)}$

Aplicación del teorema de Bayes: $P(Y=K|X=x) = \frac{f_K(x)\pi_K}{\sum_{k=1}^K f_k(x)\pi_k}$

$$X \sim N(\mu, \sigma^2) \Rightarrow P(Y=K|X=x) = \frac{\pi_K \cdot \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{1}{2\sigma^2}(x-\mu_K)^2\right)}{\sum_{s=1}^K \pi_s \cdot \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{1}{2\sigma^2}(x-\mu_s)^2\right)}$$

Note que el denominador no depende de k , por lo que se puede omitir para la comparación de clases. Al aplicar $\log(\pi_k \cdot f_k(x))$ se obtiene:

$$\begin{aligned} \log(\pi_k \cdot f_k(x)) &= \log(\pi_k) + \log\left(\frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{(x-\mu_k)^2}{2\sigma^2}\right)\right) \\ &= \log(\pi_k) + \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) + \log\left(\exp\left(-\frac{(x-\mu_k)^2}{2\sigma^2}\right)\right) \\ &= \log(\pi_k) + \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(x-\mu_k)^2}{2\sigma^2} \\ &= \log(\pi_k) + \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{(x^2 - 2x\mu_k + \mu_k^2)}{2\sigma^2} \\ &= \log(\pi_k) + \log\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{x^2}{2\sigma^2} + \frac{2x\mu_k}{2\sigma^2} - \frac{\mu_k^2}{2\sigma^2} \end{aligned}$$

Nuevamente se omiten los términos que no dependen de k :

$$= \log(\pi_k) + \frac{x\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2}$$

$$\therefore \delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k) //$$

Regla de asignación

El Análisis Discriminante asigna $X = x$ a la clase con mayor $\hat{\delta}_k(x)$ donde

$$\hat{\delta}_k(x) = x \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log \hat{\pi}_k$$

La prueba es análoga a la anterior, $\hat{f}_k(x)$ se define como:

$$\hat{f}_k(x) = \frac{1}{\sqrt{2\pi} \hat{\sigma}} \exp\left(-\frac{(x - \hat{\mu}_k)^2}{2\hat{\sigma}^2}\right)$$

Se aplica $\log(\hat{\pi}_k \cdot \hat{f}_k(x))$:

$$\begin{aligned} \log(\hat{\pi}_k \cdot \hat{f}_k(x)) &= \log(\hat{\pi}_k) + \log\left(\frac{1}{\sqrt{2\pi} \hat{\sigma}} \cdot \exp\left(-\frac{(x - \hat{\mu}_k)^2}{2\hat{\sigma}^2}\right)\right) \\ &= \log(\hat{\pi}_k) + \log\left(\frac{1}{\sqrt{2\pi} \hat{\sigma}}\right) + \log\left(\exp\left(-\frac{(x - \hat{\mu}_k)^2}{2\hat{\sigma}^2}\right)\right) \\ &= \log(\hat{\pi}_k) + \log\left(\frac{1}{\sqrt{2\pi} \hat{\sigma}}\right) - \frac{(x - \hat{\mu}_k)^2}{2\hat{\sigma}^2} \\ &= \log(\hat{\pi}_k) + \log\left(\frac{1}{\sqrt{2\pi} \hat{\sigma}}\right) - \frac{(x^2 - 2x\hat{\mu}_k + \hat{\mu}_k^2)}{2\hat{\sigma}^2} \\ &= \log(\hat{\pi}_k) + \log\left(\frac{1}{\sqrt{2\pi} \hat{\sigma}}\right) - \frac{x^2}{2\hat{\sigma}^2} + \frac{2x\hat{\mu}_k}{2\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} \end{aligned}$$

Nuevamente se omiten los términos que no dependen de k :

$$= \log(\hat{\pi}_k) + \frac{x\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2}$$

$$\therefore \delta_k(x) = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k) //$$

En el caso de $p > 1$ predictores, el clasificador LDA asume que los individuos en la clase k siguen una distribución Gaussiana Multivariada con media μ_k , y Σ es la matriz de covarianzas igual para todas las clases.

Regla de asignación

El análisis discriminante asigna $X = x$ a la clase con mayor $\delta_k(x)$ donde:

$$\delta_k(x) = x^t \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k + \log(\pi_k)$$

La Normal Multivariada se define como:

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu_k)^t \Sigma^{-1} (x - \mu_k)\right)$$

Aplicando $\log(\pi_k \cdot f_k(x))$:

$$\begin{aligned} \log(\pi_k \cdot f_k(x)) &= \log(\pi_k) + \frac{-1}{2} (x - \mu_k)^t \Sigma^{-1} (x - \mu_k) \\ &= \log(\pi_k) - \frac{\Sigma^{-1}}{2} [x^t \cdot x - x^t \cdot \mu_k - x \mu_k^t + \mu_k^t \mu_k] \\ &= \log(\pi_k) + \frac{1}{2} x^t \Sigma^{-1} \mu_k + \frac{1}{2} \mu_k^t \Sigma^{-1} x - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k \end{aligned}$$

Note que $x^t \Sigma^{-1} \mu_k = \mu_k^t \Sigma^{-1} x$, por tanto:

$$= \log(\pi_k) + x^t \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k$$

$$\delta_k(x) = x^t \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k + \log(\pi_k) //$$

Regla de asignación

El QDA asigna $X = x$ a la clase con mayor $\delta_k(x)$ donde:

$$\begin{aligned}\delta_k(x) &= -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \log \pi_k. \\ &= -\frac{1}{2} \mathbf{x}^t \Sigma_k^{-1} \mathbf{x} + \mathbf{x}^t \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma_k^{-1} \mu_k + \log(\pi_k) - \frac{1}{2} \log(|\Sigma_k|)\end{aligned}$$

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2} \cdot (x - \mu_k)^t \Sigma_k^{-1} (x - \mu_k)\right)$$

Aplicando $\log(\pi_k \cdot f_k(x))$:

$$\begin{aligned}\log(\pi_k \cdot f_k(x)) &= \log(\pi_k) - \frac{1}{2} \cdot (x - \mu_k)^t \Sigma_k^{-1} (x - \mu_k) - \log(|\Sigma_k|)^{1/2} \\ &= \log(\pi_k) - \frac{1}{2} \cdot \Sigma_k^{-1} (x^t \cdot x - x^t \mu_k - \mu_k^t x + \mu_k^t \mu_k) - \frac{1}{2} \log(|\Sigma_k|) \\ &= \log(\pi_k) - \frac{1}{2} x^t \Sigma_k^{-1} x + \frac{1}{2} x^t \Sigma_k^{-1} \mu_k + \frac{1}{2} \mu_k^t \Sigma_k^{-1} x - \frac{1}{2} \mu_k^t \Sigma_k^{-1} \mu_k - \frac{1}{2} \log(|\Sigma_k|)\end{aligned}$$

Note que $x^t \Sigma_k^{-1} \mu_k = \mu_k^t \Sigma_k^{-1} x$, por tanto:

$$= \log(\pi_k) - \frac{1}{2} x^t \Sigma_k^{-1} x + x^t \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma_k^{-1} \mu_k - \frac{1}{2} \log(|\Sigma_k|)$$

$$\therefore \delta_k(x) = -\frac{1}{2} \log(|\Sigma_k|) - \frac{1}{2} x^t \Sigma_k^{-1} x + x^t \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma_k^{-1} \mu_k + \log(\pi_k) //$$

3) Demuestre lo siguiente:

- a) $V = V_B + V_W$
- b) $\sum_{s=1}^r q_s g_s = 0$, por tanto $\text{rango}(C_g) \leq r - 1$
- c) $\text{rango}(C_g) = \text{rango}(V_B)$

a) $V = V_B + V_W$

Definiciones: $V = X^t D X = \sum_{i=1}^n p_i x_i x_i^t = \sum_{s=1}^r \sum_{i \in \ell_s} p_i x_i x_i^t$ (matriz covarianza total)

$$V_B = \sum_{s=1}^r q_s g_s g_s^t = C_g^t D_g C_g \quad (\text{matriz covarianza inter-clase})$$

$$V_W = \sum_{s=1}^r q_s V_s = \sum_{s=1}^r \sum_{i \in \ell_s} p_i (x_i - g_s)(x_i - g_s)^t \quad (\text{matriz covarianza intra-clase})$$

$$\begin{aligned} V_B + V_W &= \sum_{s=1}^r q_s g_s g_s^t + \sum_{s=1}^r \sum_{i \in \ell_s} p_i (x_i - g_s)(x_i - g_s)^t \\ &= \sum_{s=1}^r q_s g_s g_s^t + \sum_{s=1}^r \sum_{i \in \ell_s} p_i (x_i x_i^t - x_i g_s^t - x_i^t g_s + g_s g_s^t) \\ &= \sum_{s=1}^r q_s g_s g_s^t + \sum_{s=1}^r \sum_{i \in \ell_s} p_i (x_i x_i^t - x_i g_s^t - x_i^t g_s + g_s g_s^t) \\ &= \sum_{s=1}^r q_s g_s g_s^t + \sum_{s=1}^r \sum_{i \in \ell_s} p_i x_i x_i^t - p_i x_i g_s^t - p_i x_i^t g_s + p_i g_s g_s^t \end{aligned}$$

Observe que $q_s = \sum_{i \in \ell_s} p_i$ y $g_s = \frac{1}{q_s} \sum_{i \in \ell_s} p_i x_i \Rightarrow \sum_{i \in \ell_s} p_i x_i = q_s \cdot g_s$, por lo tanto:

$$\begin{aligned} &= \sum_{s=1}^r \sum_{i \in \ell_s} p_i x_i x_i^t + \sum_{s=1}^r q_s g_s g_s^t - q_s g_s g_s^t - q_s g_s^t g_s + q_s g_s g_s^t \\ &= \sum_{s=1}^r \sum_{i \in \ell_s} p_i x_i x_i^t \end{aligned}$$

$$= V //$$

b) $\sum_{s=1}^r q_s g_s = 0$, por tanto $\text{rango}(C_g) \leq r - 1$

$$\sum_{s=1}^r q_s g_s = \sum_{s=1}^r q_s \cdot \frac{1}{q_s} \sum_{i \in \ell_s} p_i x_i$$

$$= \sum_{s=1}^r \sum_{i \in \ell_s} p_i x_i$$

$$= \sum_{i=1}^n p_i x_i$$

= 0 \rightarrow Debido a que X está centrada

El rango es el número máximo de filas o columnas linealmente independientes de la matriz, como $\sum_{s=1}^r q_s q_s = 0$, entonces los q_s no son todas independientes. Por lo tanto,

$$\text{rango}(C_g) \leq r-1 //$$

$$c) \text{ rango}(C_g) = \text{rango}(V_B)$$

Por definición, $V_B = C_g^t D_q C_g$. Si se toma $x \in \mathbb{R}^r$:

$$V_B x = 0 \Leftrightarrow x^t C_g^t D_q C_g x = 0$$

$$\Rightarrow (C_g x)^t D_q (C_g x) = 0$$

Sabemos que $C_g x$ es la matriz con filas $q_j^t x \geq 0$ y D_q la matriz $\text{diag}(q_j)$ donde $q_j > 0$. De forma que $(C_g x)^t D_q (C_g x) = 0$ solamente cuando $q_j^t x = 0 \Rightarrow C_g x = 0$. Tenemos que V_B y C_g tienen el mismo núcleo $\Rightarrow \text{rango}(V_B) = \text{rango}(C_g)$:

$$\text{rango}(V_B) = p - \dim(\text{Ker}(V_B)) = p - \dim(\text{Ker}(C_g)) = \text{rango}(C_g) //$$

debido al teorema de rango-nulidad (p = número columnas).

Ejercicio 6

Se tiene la observación $t = (\text{Isabel}, F, 4, ?)$ por onde se quiere calcular que:

$$P(\text{Clase} = c \mid \text{Género} = F, \text{Altura} = 4)$$

En los datos de entrenamiento tenemos que hay un 14 y por clase se tiene:

$P: 3 \wedge M: 7 \wedge A: 4$ personas

Por en se tienen las probabilidades a priori:

$$P(P) = \frac{4}{15}, \quad P(M) = \frac{8}{15} \wedge P(A) = \frac{3}{15}$$

Ahora veamos la verosimilitudes condicionales:

► Para P:

$$P(F|P) = \frac{3}{4} \quad \wedge \quad P(\text{Altura} = 4|P) = \frac{0}{4}$$

$$\Rightarrow P(F, 4|M) \cdot P(M) = \frac{3}{4} \cdot 0 \cdot \frac{4}{15} = 0 //$$

► Para M:

$$P(F|M) = \frac{6}{8} \quad \wedge \quad P(\text{Altura} = 4|M) = \frac{3}{8}$$

$$\Rightarrow P(F, 4|M) \cdot P(M) = \frac{6}{8} \cdot \frac{3}{8} \cdot \frac{8}{15} = \boxed{\frac{144}{960}}$$

► Para A:

$$P(F|A) = \frac{0}{3} \quad \wedge \quad P(\text{Altura} = 4|A) = \frac{0}{3}$$

$$\Rightarrow P(F, 4|A) = 0 //$$

Por lo tanto se se sigue:

$$P(M|F, 4) = \frac{0,15}{0,15 + 0 + 0} = 1 //$$

Se concluye que Isabel será clasificada en la clase M con una proba 1 por medio del método de Naive Bayes.

7. (20 puntos) Para la siguiente tabla, se tiene una nueva fila: $12 = (1, 3, 2, 4, ?)$. Prediga manualmente si el individuo es buen pagador o mal pagador.

Id	Monto Crédito	Ingreso Neto	Monto Cuota	Grado Académico	Buen Pagador
1	2	4	1	4	Sí
2	2	3	1	4	Sí
3	4	1	4	2	No
4	1	4	1	4	Sí
5	3	3	3	2	No
6	3	4	1	4	Sí
7	4	2	3	2	No
8	4	1	3	2	No
9	3	4	1	3	Sí
10	1	3	2	4	Sí
11	1	4	2	4	Sí

Se utiliza el método de Bayes, de forma que:

$$P(Y=y | X=x) = \frac{P(Y=y) \prod_{i=1}^n P(X_i=x_i | Y=y)}{\sum_{k=1}^K P(Y=k) \prod_{i=1}^n P(X_i=x_i | Y=k)}$$

$$\text{En este caso, } P(BP=1 | X=x) = \frac{P(X=x | BP=1) P(BP=1)}{P(X=x | BP=1) P(BP=1) + P(X=x | BP=0) P(BP=0)}$$

$$\text{donde } X = 1, 3, 2, 4, P(BP=1) = \frac{7}{11} \approx 0.6364, P(BP=0) = \frac{4}{11} \approx 0.3636$$

Caso BP = Sí = 1:

Caso BP = No = 0:

$$P(\text{Monto Crédito} = 1 | BP=1) = \frac{2}{7}$$

$$P(\text{Monto Crédito} = 1 | BP=0) = \frac{0}{5}$$

$$P(\text{Ingreso Neto} = 3 | BP=1) = \frac{2}{7}$$

$$P(\text{Ingreso Neto} = 3 | BP=0) = \frac{1}{5}$$

$$P(\text{Monto Cuota} = 2 | BP=1) = \frac{2}{7}$$

$$P(\text{Monto Cuota} = 2 | BP=0) = \frac{0}{5}$$

$$P(\text{Grado Académico} = 4 | BP=1) = \frac{6}{7}$$

$$P(\text{Grado Académico} = 4 | BP=0) = \frac{0}{5}$$

$$\Rightarrow \frac{2}{7} \cdot \frac{2}{7} \cdot \frac{2}{7} \cdot \frac{6}{7} \approx 0.2999$$

$$\Rightarrow 0$$

$$\text{Por lo tanto, } P(BP=1 | X=x) = \frac{0.2999 \cdot 0.6364}{0.2999 \cdot 0.6364 + 0 \cdot 0.3636} = 1$$

∴ El individuo es buen pagador. //